

차량 영상에서의 딥러닝 기반 차종 및 번호판 식별 시스템

서준혁*, 윤현주**

Deep Learning-Based Vehicle Model and License Plate Identification System using Vehicle Images

Jun-Hyeok Seo*, and Hyeon-Ju Yoon**

요 약

오늘날, 차량은 단순 교통수단을 넘어 상업, 레저 등 다양한 분야에서 사용되고 있다. 이로 인해 차량은 하나의 정보로써 활용되고 있고, 차량의 차종과 등록 번호는 그 핵심 요소이다. 본 논문에서는 차종 식별을 위해 객체 인식 알고리즘 YOLOv5에 98,153개의 영상 데이터를 학습시켰고 그 결과로 국산 대부분 차량에 대한 모델의 인식 정확도가 거의 100%에 도달하는 결과를 도출했다. 번호판 식별을 위해 컴퓨터 비전 라이브러리인 OpenCV를 이용했고 다양한 영상처리 알고리즘을 적용한 후 OCR을 적용해 차량의 번호를 식별했다.

Abstract

Today, vehicles are used in various fields such as commerce and leisure beyond simple transportation. For this reason, vehicles are used as one piece of information, and the vehicle's model and registration number are key elements. In this paper, we trained 98,153 image data in the object recognition algorithm YOLOv5 to identify the vehicle type, and as a result, the model's recognition accuracy for most domestic vehicles reached almost 100%

Key words

Vehicle, License Plate, Model, Identification, Object Recognition, Image Processing

1. 서 론

최근 우리나라 자동차 누적등록 대수는 2,535만 6,000대로 인구 2.03명당 1대의 자동차를 보유하고 있는 것으로 나타났다[1]. 차량이 많아지고 교통이 혼잡해짐에 따라 교통 데이터의 중요도가 높아지고 있다.

차량은 차종과 등록 번호를 통해 소유주를 특정할 수 있는 특성이 있어, 차량 영상은 뺑소니나 차량 도난과 같은 특정 범죄의 필수적인 수사 데이터로 활용되고 있다. 또한, 무인 톨게이트와 무인 주차장과 같은 무인 시스템에서도 차종과 등록 번호의 인식은 필수적이다. 차종과 번호판의 인식에 대해서는 객체 인식 알고리즘을 통한 차종 인식과

* 금오공과대학교 컴퓨터공학과 ssam2s@kumoh.ac.kr

** 금오공과대학교 컴퓨터공학과 juyoon@kumoh.ac.kr

OCR(Optical Character Reader)을 이용한 번호판 인식이 개발되어 있다[2,3]. 이에 본 연구에서는 차량의 제조사와 모델 인식, 그리고 번호판 인식을 한 사이클로 처리하고, 기존 연구보다 더 많은 학습 데이터와 최신의 객체 인식 알고리즘을 적용하여 개선된 시스템을 제안하고자 한다.

II. 차종 식별 시스템 개발

본 논문에서는 차량의 제조사와 모델명을 구별할 수 있는 시스템을 제안한다. 유사한 기존 연구에서, 최신의 객체 인식 알고리즘인 YOLOv5[4]와 더 많은 데이터셋을 이용해 개발된 시스템은 더 향상된 성능을 보였다.

2.1 데이터셋 전처리

본 논문에서는 객체 인식 모델 학습을 위해 국내 인공지능 공개 데이터 플랫폼인 ‘AI-Hub’에서 제공하는 ‘차량 외관 영상’ 데이터를 사용했다. 2021년에 구축되어 2022년 8월에 최종 갱신된 데이터셋을 사용했으며 해당 데이터셋은 차량 100종에 대한 트림, 색상별 영상 데이터 약 1,100,000장과 JSON 타입의 라벨링 데이터로 이루어져 있다[5].

영상에 대해 Bounding Box를 표현할 때, 일반적으로 좌측 상단 좌표와 우측 하단 좌표를 Box를 태깅한다. 이에 반해, 본 논문에서 사용한 YOLOv5는 영상의 중심점 좌표를 잡고, 영상의 스케일을 이용해 Width 값과 Height 값을 이용해 Box를 태깅한다. 따라서, 라벨 데이터의 좌표값을 다음과 같은 공식을 이용해 YOLOv5의 좌표값 형식으로 변환해주었다.

$$\begin{aligned}x_{yolo} &= (x + \frac{w}{2}) / w_{img} \\y_{yolo} &= (y + \frac{h}{2}) / h_{img} \\w_{yolo} &= w / w_{img} \\h_{yolo} &= h / h_{img}\end{aligned}$$




그림 1. 일반적인 Bounding Box 좌표 설정 방식과 YOLO의 좌표 설정 방식

Fig 1. Typical Bounding Box Coordinate Setting Method and YOLO Coordinate Setting Method

추가로, 위 식으로 처리된 라벨 데이터에 총 100개 차종을 구분하기 위해 각 차종에 대한 클래스를 0 ~ 99까지 지정해주었으며, 각 클래스의 이름을 HYUNDAI_SONATA와 같은 예시로 정해주었다.

영상 데이터에는 차량 전체 사진뿐만 아니라 각 부위별 사진 또한 포함되어있었기 때문에, 차량 전체가 찍힌 사진만 분리해낸 결과 총 98,153쌍의 영상 데이터와 라벨 데이터를 얻을 수 있었다.

본 연구에 사용된 데이터셋 제공처의 설명에 따르면, 학습 : 검증 : 테스트 데이터의 비율을 8 : 1 : 1의 비율로 구성하는 것을 권고하였다. 따라서, 각 차종의 색상에 대한 Augmentation을 고려하여 데이터를 79,186 : 9,660 : 9,307의 비율로 분배했다.

2.2 YOLOv5 모델 학습

본 연구는 Google에서 제공하는 클라우드 기반 개발 환경인 ‘Google Colab’에서 학습을 진행했다. 온라인 환경에서 진행하는 학습의 영향으로, 약 15,000개 이상의 데이터를 한 번에 학습시키려고 시도하면 Runtime Error가 발생하여 학습용 데이터 약 80,000개를 10,000개씩 8개로 나누어 학습시키는 방식으로 진행했다.

본격적인 학습에 앞서 최적화된 하이퍼 파라미터를 설정하기 위해 이미지 크기는 640, 배치 크기는 16, 반복 횟수는 100으로 설정하고 시험 학습을 진행했다.

시험 학습 결과의 학습 데이터에 대한 Class Loss 그래프에서, Epoch 50을 기준으로 Loss가 0.02 이하로 떨어지는 것을 확인할 수 있었다. 하지만, 검증 데이터에 대해서는 그림 2와 같이 과적합이 발생한 것을 확인할 수 있었다.




그림 2. 반복 횟수를 100으로 설정하여 학습한 결과 Loss 그래프

Fig 2. Loss Graph of Results Learned by Setting the Number of Epoch to 100

검증 데이터에 대한 Class Loss는 Epoch 50을 기준으로 값이 거꾸로 상승했으며, Precision Score 또한 Epoch 50을 기준으로 값이 급격하게 하락했다. 따라서, 반복 횟수를 50으로 설정하고 본 학습을 진행했다.

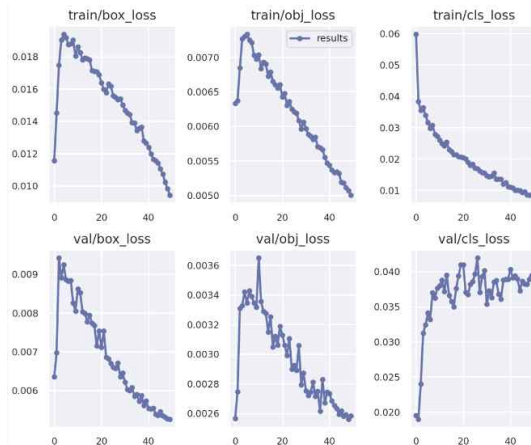


그림 3. 최종 학습에 대한 결과 Loss 그래프

Fig 3. Result Loss Graph for Final Learning

그림 3은 마지막 학습에 대한 Loss 그래프이다. 학습데이터에 대한 모든 Loss 그래프가 0.02 미만의 수치에 도달했으며, 검증 데이터에 대한 Loss 그래프도 큰 이상이 없음을 확인했다.

검사 기준 IOU를 0.5 ~ 0.95로 변경해가면서 mAP(Mean Average Precision)을 측정한 결과, 그림 4와 같이 0.677에 도달함으로써 경험적으로 꽤 좋은 결과를 보이는 것을 확인할 수 있었다.




그림 4. Precision-Recall Curve와 mAP 점수

Fig 4. Precision-Recall Curve and mAP Score

2.3 차종 식별 성능 측정

실제 인식 성능을 확인하기 위해, 테스트 데이터셋 중 약 1,000장에 대해 인식 테스트를 진행했다. 학습이 1,000장 이상 된 차종에 대해서는 그림 5와 같이 Confidence Score가 98% 이상으로 상당한 신뢰도를 보였으며 박스 태깅과 모델 식별에 있어서도 성공적인 결과를 보였다.



그림 5. 실제 영상에 대한 인식 및 모델 식별

Fig 5. Recognition of Actual Images and Model Identification

다른 차량이 함께 찍혀있는 영상에서도 차량이 가까워 특징점을 파악할 수 있는 영상은 그림 6과 같이 어느 정도 동시 인식을 할 수 있는 것을 확인했다.

III. 번호판 영역 검출 및 인식



그림 6. 실제 영상에 대한 동시 인식

Fig 6. Simultaneous Recognition of Actual Images

인식 성능 테스트는 100개의 차종 중 무작위로 뽑은 61개의 차종에 대해 진행했다. 다음 표 1은 인식 성능 테스트를 진행한 차종의 학습 데이터 수와 인식 성능을 정리한 표이다.

차종	학습 수	테스트 수	인식률	정확도
카니발	2,255	32	100%	100%
스포티지	2,038	29	100%	100%
레이	2,091	26	100%	100%
싼타페	2,072	31	100%	100%
티볼리	1,950	37	100%	100%
스텅어	1,556	16	100%	100%
투싼	1,458	34	100%	100%
스타렉스	1,301	13	100%	100%
K7	2,245	66	100%	96.9%
EQ900	853	20	100%	95%
기타	49,113	696	80.7%	61.2%
계	66,932	1,000	86.6%	72.7%

표 1. 실험에 사용한 차종과 해당 차종의 학습 데이터 수 및 인식률과 정확도

‘기타’ 차량은 테스트에 사용된 상위 10대의 차량을 제외한 나머지 차종을 의미한다. 학습 수는 테스트에 사용된 차종의 학습 데이터 수를 의미하며 테스트 수는 테스트에 사용된 차종의 테스트 영상 수를 의미한다. 인식률은 올바르게 박스가 태깅되었는가를 평가하였으며 정확도는 모델 분류를 올바르게 했는가를 평가하였다.

학습 데이터 수가 충분해 1,000장 이상 학습시킬 수 있었던 차량에서는 인식률과 정확도가 거의 100%에 수렴하게 나왔지만, 데이터 수가 1,000개 미만으로 빈약했던 차종에서는 정확도와 인식률이 기하급수적으로 하락해 차종별 인식률과 정확도에 있어 큰 편차를 보였다.

번호판 영역 검출을 위해 사용된 영상의 크기는 1296*964이다. 차량 번호판이 비교적 중앙 부근에 분포해있는 영상으로 검출 및 인식을 진행했다.

Gaussian Blurring, Morphology 연산, Adaptive Thresholding을 이용해 전처리한 영상에 에지 검출을 진행했고 컨투어 영역을 그린 후 번호판 숫자 배열의 형태를 띄는 컨투어를 번호판으로 추정하는 방식을 이용하여 번호판을 검출했다. 처리 단계는 아래 그림의 순서로 진행되었다.



그림 7. 입력 영상과 전처리 후의 영상

Fig 7. Input Image and Preprocessed Image




그림 8. 검출된 에지의 영상과 후보 영역 영상

Fig 8. Extracted Edges Image and Candidate Regions Image



그림 9. 번호판 위치 추정 영상과 결과 영상

Fig 9. Image which Estimates the Location of the License Plate and the Result Image

최종 검출한 번호판 영역은 기울기가 수평이 아니기에 OCR 인식 정확도 하락을 유발할 수 있는 점을 고려하여 다음과 같은 각도 계산 공식을 적용하여 각도를 구하고, 기울기를 보정 후 그림 10과 같이 추출했다.

$$\theta = \arctan \frac{|y_2 - y_1|}{|x_2 - x_1|} \times \frac{180}{\pi} \quad (1)$$

60리 3956

그림 10. 최종 추출된 번호판 영상

Fig 10. Finally Cropped License Plate Image

최종적으로 번호판 인식을 위해 오픈소스 OCR 중 Easy OCR[6]을 사용하여 앞서 구현했던 차종 식별과 함께 실행한 결과, 테스트 영상에 대해 인식을 수행한 결과, 그림 11과 같이 차량 번호와 차종 모두 올바르게 식별하는 것을 확인할 수 있었다.



그림 11. 연구 최종 결과 영상

Fig 11. Final Result Image of the Research

IV. 결 론

본 논문에서는 차종 식별을 위해 딥러닝 기반 객체 인식 알고리즘 모델인 YOLOv5에 YOLO 데이터 포맷으로 전처리된 다량의 데이터셋을 최적의 하이퍼 파라미터를 찾은 후 학습시켰고 약 1,000장 이상

의 충분한 학습 데이터가 보장되었던 차종에 대해서는 훌륭한 성능을 보이는 것을 확인했다. 상대적으로 성능이 빈약한 차종에 대해서는 데이터를 더 추가하거나 나눈 데이터 조각이 서로 교집합을 가지도록 구성하여 Global Minimum 문제를 조금 해소하여 성능 향상을 기대할 수 있을 것이고, 로컬 GPU 환경에서 한 번에 학습시킨다면 더 나은 성능을 보일 수 있을 것이다. 또한, 클라우드 환경에서의 파일시스템 입출력에 대한 속도 개선 연구가 이루어진다면 딥러닝 모델 학습에서 더욱 축소된 과정을 기대할 수 있을 것으로 보인다.

번호판 식별을 구현하기 위해 입력 영상에 다양한 영상처리 기법을 사용하여 전처리를 수행하고 번호판의 특징점을 분석해 영상의 에지와 그 비율을 비교하는 방식으로 번호판을 추출했다. 추출한 번호판 영상에 대해 OCR을 적용하여 문자열 데이터로 읽어내는 과정을 거쳤고 훌륭한 성능을 보여 최종적으로 차종과 번호판 식별이 한 사이클에 처리된 결과를 볼 수 있었다.

참 고 문 헌

- [1] 국토교통부, “3분기 자동차 등록 2535만대… 친환경차 늘고 경유·LPG 줄어”, 대한민국 정책브리핑, 2022.10.28., <https://www.korea.kr/news/policyNewsView.do?newsId=148907575>
- [2] 권혁호, 박성현, 임준호, 장성원, 김수민. (2019). OCR 기반 모바일 차량번호판 인식 시스템. 한국통신학회 학술대회논문집, (), 465-466.
- [3] 이보람, 장윤아, 박성건, 박호성. (2019). 헤드라이트 이미지 분석을 통한 YOLO 기반 차종 인식 기법. 한국통신학회 학술대회논문집, (), 945-946.
- [4] YOLOv5 (2022) Repository [Source Code]. <https://github.com/ultralytics/yolov5>
- [5] AI-Hub, 차량 외관 영상 데이터, (2021). <https://aihub.or.kr/aihubdata/data/view.do?currMenu=115&topMenu=100&aihubDataSe=realm&dataSetSn=554>
- [6] EasyOCR (2022) Repository [Source Code]. <https://github.com/JaidedAI/EasyOCR>